ResNet 모델 포멧 변화 실험 보고서

perweekdev@gmail.com

1. 실험 개요

- **프로젝트 목표**: ResNet18 모델을 PyTorch FP32 기준으로 동적 양자화 및 ONNX 변환을 통해 추론 속도, 모델 용량, 정확도 성능을 종합적으로 비교 평가한다.
- **실험 방법**: CIFAR-10 테스트 데이터셋에서 100개 샘플을 대상으로 배치 추론을 수행하며, 10회 반복 후 평균 추론 시간 및 정확도를 측정한다.

2. 모델 변환 결과

- **기반 모델**: ResNet18 (ImageNet 사전학습 가중치 기반, CIFAR-10 데이터셋으로 파인튜닝)
- **데이터셋**: CIFAR-10 (10개 클래스 분류, 32×32 해상도 컬러 이미지)
- **변환방법**:
  - **PyTorch FP32**: 기준 모델, state_dict 저장
  - **PyTorch Quant**: Linear 계층 동적 양자화 (qint8)
  - **ONNX**: ONNX export (opset=11, external_data=True)

3. 추론 성능 비교

- **측정 환경**: CPU 환경에서 배치 사이즈 100으로 10회 반복 평균값

모델	정확도 (%)	평균 추론시간 (ms)	모델 용량 (MB)
PyTorch FP32	55.0	24.75	42.73
PyTorch Quant	55.0	23.49	**42.72**
ONNX	55.0	**9.02**	42.77*

* `ONNX:` .onnx(0.09MB) + .onnx.data(42.69MB) = 총 42.77MB

- **성능 분석**:
  - **정확도**: 모든 모델에서 55.0%로 동일 (55/100 정확 분류)
  - **추론 속도**: ONNX 모델이 64% 향상 (24.75ms → 9.02ms)
  - **모델 용량**: 동적 양자화 0.01MB 감소, ONNX도 data 포함 시 FP32와 유사(외부 데이터 분리 저장)

4. 결론

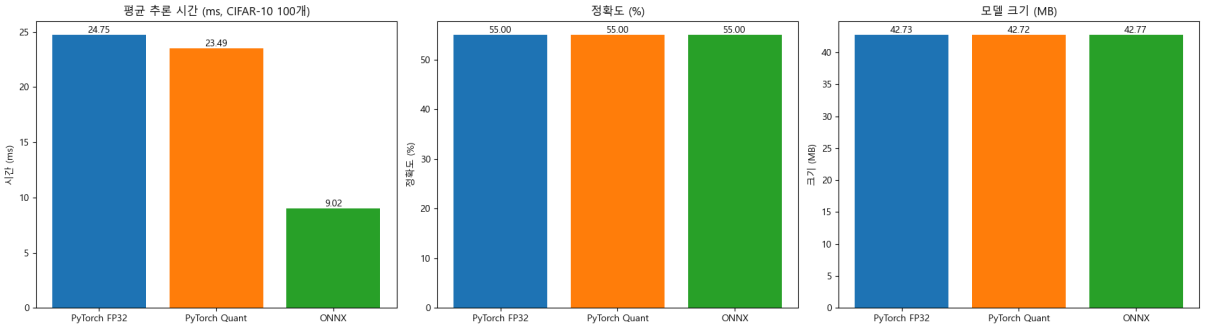

- **종합 성능 비교**:
  - ONNX 모델이 **추론 속도 64% 향상**(24.75ms → 9.02ms)에서 압도적 우수성을 보였으며, 정확도는 모든 모델에서 동일한 55.0% 수준을 유지하였다.
  - 모델 용량은 ONNX external data 포함 시 FP32와 유사하였으며, 모든 모델이 비슷한 크기를 가진다.
- **동적 양자화 효과 분석**:
  - 동적 양자화는 Linear 계층만 대상으로 수행되어 Conv2d 계층(파라미터 90% 이상)이 FP32로 유지됨에 따라 용량 감소폭이 0.01MB에 그침.
  - Static 양자화(전체 계층 대상) 또는 경량 백본 적용시 더 큰 용량 감소 효과를 기대할 수 있다.
- **ONNX External Data 고려사항**:
  - ONNX export 시 external_data=True로 모델 파라미터가 외부 파일로 분리되어 .onnx 파일 자체는 0.09MB로 매우 작아졌으나, 실제 데이터 파일과 함께 배포가 필요하다.
- **일반화 제약사항**:
  - 본 실험은 CPU 환경 및 CIFAR-10 데이터셋(파인튜닝 부족으로 55% 정확도)에 국한되며, 실제 서비스 도메인 및 충분한 파인튜닝 후에는 성능 차이가 달라질 수 있을 것이다.